

1. Synthèse Exécutive & Objectifs

KhmerAgriBot est une solution intégrée d'assistance agronomique par messagerie Telegram, conçue pour opérer directement au profit des exploitants agricoles et vulgarisateurs ruraux au Cambodge. Le système assure des diagnostics fiables, auditables et en temps réel pour deux cultures prioritaires : le **riz pluvial/bas-fond** et le **manioc**.

Objectifs Techniques & Métier Validés

- Autonomie système complète** : Démon de fond orchestré via `systemd` garantissant le redémarrage automatique en cas d'interruption.
- Télémétrie et auditabilité intégrale** : Enregistrement de chaque interaction en base relationnelle (PostgreSQL) avec latences RAG, temps LLM, modèles et retours des utilisateurs.
- Diagnostic multimodal résilient** : Reconnaissance visuelle via `gemini-3.6-flash` interdisant formellement toute confusion morphologique entre le riz et le manioc.
- Base de connaissances vectorielle sécurisée** : RAG sémantique propulsé par `pgvector` (dimension 3072) avec recherche cosinus cross-lingue (Khmer ↔ Français ↔ Anglais).
- Workflow linguistique strict FR → EN → KH** : Préservation des fiches institutionnelles (CARDI, CIAT, CIRAD), pivot de raisonnement en anglais, et restitution finale en khmer agricole soigné.

2. Architecture Technique et Flux de Données

Flux séquentiel de traitement d'une requête utilisateur :

- Réception Telegram** : Ingestion de texte brut, légende ou image compressée via `python-telegram-bot`.
- Extraction de contexte pédologique** : Interrogation de données de sol (pH, texture, argile) via SoilGrids avec repli automatique sur le profil régional.
- Recherche sémantique vectorielle** : Vectorisation de la requête en dimension 3072 (`gemini-embedding-001`) et projection cosinus sur `rag_documents`.
- Raisonnement et génération LLM** : Le moteur `gemini-3.6-flash` synthétise le diagnostic en anglais avant de produire la réponse finale en khmer.
- Enregistrement d'audit** : Écriture de la télémétrie complète et affichage des boutons de retour (👍 / 👎) pour évaluation continue.

3. Spécifications des Composants Logiciels

Composant	Technologie	Fonction et Paramètres de Déploiement
Supervision Linux	systemd	Service <code>khmeragribot.service</code> , redémarrage sous 5s, exécution sous compte <code>hermes</code> .
Base de données	PostgreSQL 16 + pgvector	Stockage relationnel des logs et indexation sémantique sur vecteurs dimension 3072.
Modèle d'Embedding	gemini-embedding-001	Vectorisation textuelle native en 3072 dimensions, alignement multilingue direct.
Modèle de Raisonnement	gemini-3.6-flash	

Composant	Technologie	Fonction et Paramètres de Déploiement
		Raisonnement complexe, vision multimodale et traduction agronomique spécialisée.
Pipeline RAG	Dropzone sécurisée	Surveillance de répertoire, sanitization, validation de pertinence et segmentation (1200 char).

4. Schéma de Base de Données

La base `khmeragribot` intègre deux tables complémentaires :

Table de Télémétrie : `interactions`

```
CREATE TABLE interactions (  
  id SERIAL PRIMARY KEY,  
  telegram_id BIGINT NOT NULL,  
  has_text BOOLEAN DEFAULT FALSE,  
  has_photo BOOLEAN DEFAULT FALSE,  
  raw_user_text TEXT,  
  rag_ms INTEGER DEFAULT 0,  
  llm_ms INTEGER DEFAULT 0,  
  total_ms INTEGER DEFAULT 0,  
  soil_source TEXT,  
  model_used VARCHAR(100),  
  confidence_score INTEGER DEFAULT 0,  
  rating_thumb SMALLINT DEFAULT NULL, -- 1 = Positif, -1 = Négatif  
  created_at TIMESTAMPTZ DEFAULT NOW()  
);
```

Table Vectorielle RAG : `rag_documents`

```
CREATE TABLE rag_documents (  
  id SERIAL PRIMARY KEY,  
  source_title TEXT NOT NULL,  
  category VARCHAR(50) DEFAULT 'general',  
  content TEXT NOT NULL,  
  embedding vector(3072),  
  created_at TIMESTAMPTZ DEFAULT NOW()  
);
```

5. Pipeline d'Ingestion Documentaire et Sécurité

Le module `ingest_files.py` applique quatre niveaux de filtrage avant d'autoriser la vectorisation d'un fichier déposé dans `~/hermes-francotech/rag_dropzone/` :

- **Validation volumétrique** : Tout fichier extrayant moins de 150 caractères est rejeté (élimination des pages vierges et scans sans OCR).
- **Intégrité d'encodage** : Contrôle d'un ratio minimal de 85% de caractères imprimables pour écarter les binaires corrompus.
- **Garde-fous sémantiques** : Obligation d'identifier au moins 2 termes de la nomenclature agricole cambodgienne.
- **Détection anti-injection** : Blocage systématique des séquences d'évasion de prompt (`ignore previous instructions`).

Gestion des flux après traitement

Les documents validés sont découpés avec chevauchement (1200/150 caractères), vectorisés puis archivés dans `rag_processed/`. Tout document non conforme est transféré dans `rag_rejected/` avec justification loggée.

6. Feuille de Route et Extensions Futures

1. **Ingestion Telegram Administrateur** : Commande `/upload_doc` conditionnée à une whitelist d'identifiants Telegram pour l'ingestion sans terminal.
2. **Streaming Audio Natif** : Prise en charge des notes vocales Telegram (fichiers OGG/Opus) envoyées directement au moteur Gemini.
3. **Géolocalisation Précise** : Remplacement des coordonnées GPS par défaut via le bouton de partage de localisation natif de Telegram.